实验一：基于 TF-IDF 的新闻文本分类

仓库地址：https://github.com/Qiuxulan/Contemporary-Artificial-Intelligence_26Fall.git

1. 实验目标与设置

本实验基于 TF-IDF 上的新闻文本分类问题，探索 NB、LR、SVM 和 MLP 四个模型的性能，围绕**模型容量、文本表示与泛化稳定性**开展探索。先建立基础结果，再分析结果，或进一步控制变量对照检验解释。

数据与表示: 7368 条标注样本按 seed=42 划分为训练集 5894 条、验证集 1474 条；2457 条无标签测试样本保留。文本转小写，基础表示为最多 5000 维、L2 归一化的 TF-IDF。先划分再只用训练子集拟合词表和 IDF，避免泄漏。

评价与选模: 统一以验证集 Macro-F1 选模，并报告 Accuracy、Macro-P、Macro-R；以训练 F1 和 F1 gap=Train F1−验证 F1 辅助分析拟合程度。最终使用全部标注数据重训，测试集不参与调参。

探索范围: 49 组基础参数扫描、20 组文本处理对照、60 组 SGD 组合、3 组特征预算对照、10 组多 seed 评估。完整原始记录见仓库下 Project1/sweep_results.csv，分组结果见 Project1/results.md。

2. 参数选择与模型表现

2.1 模型原理与最佳方案 NB 基于类别条件独立假设估计词特征概率；LR 以对数损失学习线性边界；SVM 通过间隔约束分类；MLP 以 ReLU 隐藏层学习非线性组合，使用 Adam 优化。另用 SGD 优化 log_loss 与 hinge，得到 LR-SGD 和线性 SVM-SGD。**RBF SVM 的优势体现了非线性核与文本表示的共同作用**；LR-SGD 与默认 LR 的差异则涉及优化方式、多分类处理与正则化标度。测试后各模型的最佳性能配置如下表：

模型	文本表示与关键参数	Accuracy	Macro-P	Macro-R	Macro-F1
NB	词干化，5000 维，默认参数	0.89620	0.89859	0.89632	0.89654
LR	去停用词，5000 维，C=100	0.91588	0.91700	0.91605	0.91618
LR-SGD	停用词，5000 维，α=1e−5，参数平均	0.91927	0.92022	0.91943	0.91957
SVM-SGD	原始文本，5000 维，α=1e−4，参数平均	0.91791	0.91826	0.91798	0.91794
MLP	原始文本，5000 维，隐藏层(100,)，α=0.001	0.91859	0.91986	0.91871	0.91897
SVM(RBF)	词干化，20000 维，C=1000，gamma=scale	**0.92402**	**0.92674**	**0.92404**	**0.92478**

2.2 正则化、迭代次数与核尺度 （见 results.md 第 1–3 节）

-LR：**减弱正则化改善了欠拟合**。C 是正则化强度的倒数，C 从 0.1 增至 100，训练 F1 从 0.90044 升至 0.99983，验证 F1 从 0.84331 升至 0.91487。每个 C 下，迭代上限由 1000 增至 2000 均无收益，表明当前迭代上限已足够。

-线性 SVM：**放松约束持续有效，收益逐渐饱和**。C 控制训练误分类和间隔违例的惩罚。C 从 0.1 增至 1000，F1 从 0.82162 升至 0.91177，但最后数量级只增加 0.00060。F1 持续上升，说明减弱约束仍有利于当前数据的分类。

-RBF SVM：gamma 决定 RBF 核对文档差异的敏感程度。gamma =auto=1/5000 在 C≤10 时 F1 只有 0.01847，是近似单类预测的指标特征。**这是因为归一化 TF-IDF 下，auto 给出的过小 gamma 使核值趋近**，让不同文档算出来的相似度都接近 1，模型难以区分。增大 C 能让模型更努力拟合训练数据，但难以完全弥补这种相似度区分不足。因此 C=1000 时，auto 虽然改善到 0.89231，仍低于 scale 的 0.91541。

2.3 网络容量、训练充分性与过拟合风险 **-中等容量的单层网络表现最佳**。几种隐藏层配置下，(100,)的 F1 最佳。5000 维输入 10 类输出下，单层(100,)与双层(100,50)约有 50.11 万、50.57 万个参数，增量很小。双层退化可能与额外非线性改变优化路径、50 维中间层压缩信息有关。**说明增加层不一定能提升，有过拟合的风险**。

-增加 epochs 要结合停止条件与验证表现。(100,)在 α=0.001 时最好，增至 0.1 后 F1 降至 0.91520，结构与正则化需联合选择。当前 MLP 最大 300 epoch，实际在 165 epoch 停止，**仅提高上限未必增加训练**；几组配置训练 F1 较高而验证 F1 较低，**说明训练拟合好不等于泛化好**。综合下来，单层 100 个神经元配合适度正则化较好地平衡了表达能力与训练难度；增加容量时，学习率和停止条件也需要随之适配。（见 results.md 第 4 节）

2.4 高维稀疏文本的模型适配性 统一原始文本、5000 维时，LR、RBF SVM、MLP 的 F1 为 0.91487、0.91541、0.91897（见 results.md 第 5 节）。**但经过词干化与特征预算优化后，RBF SVM 获得最高 F1。**由于主题词已具判别性，高维稀疏表示较易被线性加权区分；并且 TF-IDF 降低普遍高频词的影响，正则化和间隔约束进一步限制无效自由度。**因此 LR、SVM 无需复杂网络即可取得较强结果。**相比 MLP 需从有限样本中学习大量输入权重，高维稀疏特征使许多权重获得的训练信号较少，增加优化难度和过拟合风险，**因此额外网络复杂度未必能转化为收益。**

3. 文本处理与特征预算

先固定模型参数与 5000 维预算：NB 默认；LR 是 C=100；RBF SVM 是 C=1000、gamma=scale；MLP 为(100,)、α=0.001。下表记录了固定参数下不同文本处理的 Macro-F1。（见 results.md 第 5–9 节）

文本处理	NB	LR	SVM	MLP	去停用词	0.8940	**0.9161**	*0.9169*	0.9155
原始文本	0.8880	0.9148	0.9154	***0.9189***	Porter 词干化	**0.8965**	0.9143	***0.9213***	0.9106
单词 + 词组	0.8589	0.9013	0.8986	*0.9088*	去邮件头	0.8669	0.8845	*0.8952*	0.8832

3.1 二元词组的预算竞争检验 **-观察与假设**：加入二元词组后四模型均降分。**猜想单词与词组竞争 5000 个名额，可能挤掉有用单词。**如果猜想成立，扩大预算应使词组方案恢复更多。（见 results.md 第 18 节）

-针对性对照：保持其余参数设置不变，将 SVM 预算扩至 20000，比较单词、二元词组和词干化。结果如下表：

SVM 文本表示	5000 维 F1	20000 维 F1	增量	单词 + 二元词组	0.89867	0.91881	+0.02014
单词	0.91541	0.92348	+0.00807	词干化单词	0.92135	0.92478	+0.00343

-验证结论：词组增幅为 0.02014，高于单词 0.00807，**支持特征名额竞争是小预算下降分原因之一。**同预算仍弱于单词，稀有词组统计不稳定或参数适配也可能影响效果；词干化增幅小，可能因词形合并已缓解部分覆盖不足。

3.2 词干化的模型依赖性 词干化使 NB、RBF SVM 的 F1 分别提高约 0.00854、0.00594，却使 MLP 下降约 0.00837（见 results.md 第 5、8 节）。这一对照验证了词干化收益具有模型依赖性。词形归并可能改善 NB 的统计估计与 RBF 核的文档距离；对 MLP，合并判别词形及改变输入分布，则可能削弱原有特征组合与训练参数的适配性。

3.3 停用词处理的收益与信息损失 去停用词使 NB、LR、SVM 小幅改善，MLP 却下降。**移除高频词可能释放特征名额，但也可能丢失风格或组合线索**。SGD 同样，收益仍依赖模型与数据分布。（见 results.md 第 7、10、14 节）

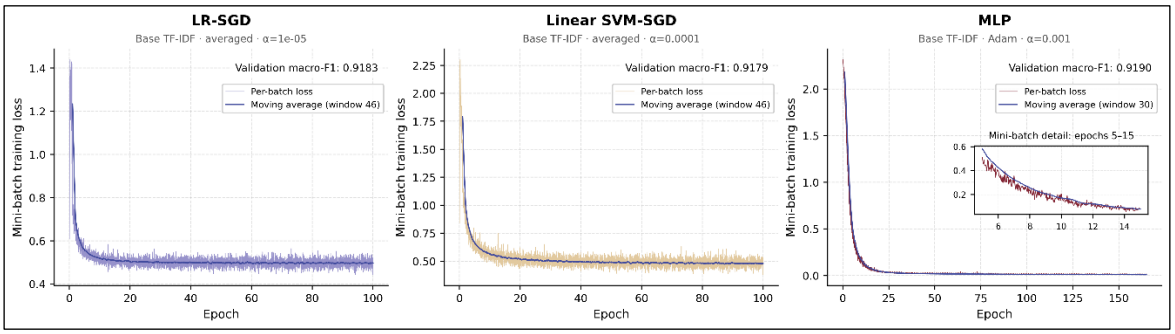
3.4 去邮件头处理的发现 去邮件头降分后，我检查发现自定义 preprocessor 取消了默认转小写，对照不公平，所以恢复了.lower()。四模型均下降，例如 SVM 从 0.91541 到 0.89529，表明**删除邮件头会降低当前划分的分类效果**（见 results.md 第 9 节）。这是因为邮件头可能提供主题、组织或来源线索，有利于模型提升判别能力。

4. 优化过程、泛化与结论

4.1 SGD 正则化、参数平均与配置迁移 SGD 中的 α 控制正则化强度，也参与默认学习率计算；average 则对训练过程中的模型参数取平均，使结果更稳定。去停用词 LR-SGD 在 α=1e−5 时，启用参数平均使 F1 从 0.91677 升至 0.91957，而 α=1e−6 时有下降，说明两者需要联合选择。α 增至 0.01 且启用平均后，验证 F1 降至 0.82768，**表明约束过强导致欠拟合**，即使训练—验证差距较小，模型表现仍然较差（见 results.md 第 10–15 节）。

发现原始文本下有更优参数后，我将两个 SGD 模型各自排名前三的参数组合用于去邮件头和词干化，检验此前的低分是否与参数不匹配有关。词干化 LR-SGD 的 F1 由原配置的 0.91041 升至 0.91824，说明清洗效果与模型参数有关联，选择更合适的 α 和参数平均组合，可改善同一种文本处理下的验证表现（见 results.md 第 16、17 节）。

4.2 逐批损失与收敛分析 原始 LR 和 SVC 的 fit 接口将训练过程封装起来，不提供逐批训练损失记录，因此本实验用 SGD 分别优化对数损失与 hinge 损失，**逐批更新模型参数，并记录当前批次的 loss 来绘制训练曲线**。LR-SGD、SVM-SGD、MLP 三模型使用相同划分与输入来绘制 loss 曲线。逐批记录 loss，以保留批次难度与随机更新带来的波动，再用一个 epoch 的批次数作移动平均窗口来平滑损失。具体配置与分类指标见 results.md 第 20 节。下图曲线前期快速下降、后期收益递减，**表明主要拟合收益集中在早期**；批次间样本难度和更新方向不同，会带来局部波动。SGD 记录更新后的批次损失，MLP 记录反向传播时的更新前损失。



4.3 训练验证差距与跨划分稳定性 MLP 与最佳 RBF SVM 的训练 F1 均为 1，验证 F1 分别为 0.91897、0.92478。两者已能充分拟合训练样本，但泛化还有差距，剩余误差可能来自样本特有词汇、类别边界重叠等等，因此需要转向探索验证表现与稳定性。将两模型都设为 5000 维 stem，在 seed 0–4 上配对评估固定参数，得到 SVM 与 MLP 的 Macro-F1 均值±样本标准差为 0.91247±0.00573、0.90845±0.00683。SVM 五次均较高，配对平均差约 0.00402（见 results.md 第 19 节），说明**优势具有一致性**，而较小样本标准差也说明这套配置对随机条件更稳健。

4.4 性能与复杂度权衡 最佳 RBF SVM 的 F1 有 0.9248，训练—验证 gap 由原始 5000 维的 0.0846 降至 0.0752，**扩大特征同时差距缩小，说明新增词特征带来了有效信息，但 20000 维输入和支持向量核计算也增加了计算需求**。而 5000 维、10 类下的 LR 及两种线性 SGD 约有 5 万个参数，MLP(100,)约有 50 万个。因此，性能优先时选择 RBF SVM，重视扩展性时可选择 F1 为 0.91957 的 LR-SGD。最终六模型按各自最优配置重训，输出 predictions.csv。

4.5 替代表示与实验总结

除 TF-IDF 外，**词袋**用词出现的次数表示文本，但容易受高频词和文章长度影响；**Word2Vec** 将词转成向量，让含义相近的词具有相近表示，但简单平均会丢失词序，且对专业术语和训练中没见过的词处理较弱；**BERT** 能结合上下文理解词义和词序，但计算成本较高，长文本可能被截断，小数据集上也有过拟合风险。这些表示分别针对词频权重、词义共享和上下文建模，适合解决不同的信息缺口，选用时需同时考虑**语义收益与计算成本**。

本次实验表明，**基础参数与文本表示均影响模型表现**。适当减弱正则化改善了欠拟合，核尺度需匹配输入特征，增加网络深度或训练轮数的收益则取决于优化条件。文本清洗方面，停用词删除和词干化的收益具有模型差异，去邮件头可能损失有用信息。通过扩大特征预算、参数迁移及多 seed 验证，我进一步探索了模型在多样配置下的性能，最终兼顾验证性能与模型复杂度选择方案。体现了从参数比较、现象分析到对照验证的完整探索过程。